


## Teorema (Eckart-Young)



A melhor aproximação de posto- $r$  da matriz no contexto de mínimos quadrados, é dada pela decomposição SVD de posto- $r$  e denotada por  $A_r$ , ou seja

$$\arg \min_{\substack{A_r, \text{ sujeito} \\ \text{posto}(A_r) = r}} \|A - A_r\|_F = \hat{U} \hat{\Sigma}_r \hat{V}^* \\ \text{ou} \\ \hat{U}_r \hat{\Sigma}_r \hat{V}_r^*$$

Neste caso,  $\hat{U}$  e  $\hat{V}$  denotam as primeiras colunas principais de  $U$  e  $V$ , enquanto que  $\hat{\Sigma}_r$  contém a submatriz  $r \times r$  de  $\hat{\Sigma}$  principal.

Resultado importante: quantificação do erro da aproximação

$$\|A - A_r\|_F^2 = \sum_{k=r+1}^n \sigma_k^2$$

Obs.  $A \in \mathbb{C}^{m \times n}$ ,  $A = \begin{bmatrix} | & | & & | \\ a_1 & a_2 & \dots & a_n \\ | & | & & | \end{bmatrix}$

Em geral, adota-se a normalização do erro

$$\frac{\|A - A_r\|_F^2}{\|A\|_F^2}$$

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} \quad (\text{Frobenius})$$

Considerando a norma-2, norma espectral, podemos reescrever o teorema como:

$$\arg \min_{\substack{A_n, \text{ sujeito} \\ \text{rank}(A) = n}} \|A - A_n\|_2 = \hat{U} \hat{\Sigma} \hat{V}^*$$

Obs.  $\|A\|_2 = \max_{v \neq 0} \frac{\|Av\|_2}{\|v\|_2}$

$$A - A_n = \sum_{k=n+1}^n \sigma_k u_k v_k^*$$

$$(A - A_n)v = \left( \sum_{k=n+1}^n \sigma_k u_k v_k^* \right) v, \text{ com } v_k \text{ vetores ortonormais}$$

① máximo de

$$\|(A - A_n)v\|_2 = \left\| \left( \sum_{k=n+1}^n \sigma_k u_k v_k^* \right) v \right\|_2 = \sigma_{n+1}$$

quando  $v = v_{n+1}$

$$\text{Ou seja: } \|A - A_n\|_2 = \sigma_{n+1}$$

Obs.  $A_k := u_k v_k^*$  (produto externo de colunas)

$$\begin{bmatrix} \vdots \\ \vdots \end{bmatrix} \begin{bmatrix} \vdots \\ \vdots \end{bmatrix}$$

Portanto, podemos interpretar a aproximação de posto  $n$  obtida pela decomposição SVD como a projeção de uma matriz de posto completo  $A$  em um espaço de dimensão reduzida de matrizes com posto no máximo  $n$ .



Teorema. A norma espectral de  $A$  é o maior valor singular da matriz  $A$ ,

$$\|A\|_2 = \sigma_1$$

Esse teorema justifica

$$\|A - A_n\|_2 = \sigma_{n+1}$$

Propriedades:

$$A = U \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix} V^* = \begin{bmatrix} \hat{U} & \hat{U}^\perp \end{bmatrix} \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix} V^* = \hat{U} \hat{\Sigma} V^*$$

As colunas de  $\hat{U}^\perp$  geram um espaço vetorial que é complementar e ortogonal ao espaço gerado por  $\hat{U}$ .

Ao considerarmos as matrizes de correlação  $AA^*$  e  $A^*A$  podemos descrever algumas informações:

$$AA^* = U \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix} V^* V \begin{bmatrix} \hat{\Sigma} & 0 \end{bmatrix} U^* = U \begin{bmatrix} \hat{\Sigma}^2 & 0 \\ 0 & 0 \end{bmatrix} U^*$$

$$A^*A = V \begin{bmatrix} \hat{\Sigma} & 0 \end{bmatrix} U^* U \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix} V^* = V \hat{\Sigma}^2 V^*$$

Utilizando o fato que  $U$  e  $V$  são unitárias, podemos considerar os seguintes problemas de autovalores

$$AA^*U = U \begin{bmatrix} \hat{\Sigma}^2 & 0 \\ 0 & 0 \end{bmatrix} \quad \text{e} \quad A^*AV = V \hat{\Sigma}^2$$

As colunas de  $U$  são autovetores da matriz  $AA^*$ ,  
e as colunas de  $V$  são os autovetores de  $A^*A$ .

Como os valores singulares são ordenados de forma  
decrecente em ordem de magnitude ( $\sigma_1, \sigma_2, \dots$ )  
então as colunas de  $U$  são ordenadas  
hierarquicamente de quanto correlação elas  
capturam nas colunas de  $A$ .

Note que semelhantemente  $V$  captura correlação  
nas linhas de  $A$ .

Método de captura instantânea

$$\begin{bmatrix} A \end{bmatrix} \quad \begin{bmatrix} AA^* \end{bmatrix} \quad \begin{bmatrix} A^*A \\ \vdots \end{bmatrix}$$

Ao resolvermos o problema de autovalores:

$A^*A V = V \hat{\Sigma}^2$   
obtemos  $V$  e  $\hat{\Sigma}$ . Caso haja zeros em  $\hat{\Sigma}$   
então podemos apenas considerar os valores não  
nulos (os primeiros  $r$  valores),  $\hat{\Sigma}_r$  e  
as colunas correspondentes de  $V$  (ou seja  $V_r$ ).

Com isso obtemos

$$U_r = A V_r \hat{\Sigma}_r^{-1}$$



Obs.

As colunas da matriz  $U$  formam uma base ortogonal para o espaço coluna de  $A$ .

As colunas da matriz  $V$  formam uma base ortogonal para o espaço linha de  $A$ .

Se as colunas de  $A$  são medidas espaciais no tempo, então  $U$  incorpora (enconde) os padrões espaciais e  $V$  os padrões temporais.

## SVD e transformações Unitárias

Considere uma transformação unitária à esquerda de  $A$ , ou seja

$$Y = CA$$

Calculando a matriz de correlação

$$Y^*Y = A^*C^*CA = A^*A$$

e portanto os dados projetados têm a mesma auto decomposição, resultando que obtemos  $V$  a  $\Sigma_A$ .

Notas: Dada uma transf. unitária à esquerda a decomposição SVD de  $A$  será denotada  $U_A \Sigma_A V_A^*$

Dada uma transf. unitária à direita por  $P^*$ ,  $Y = AP^*$ , então a decomposição SVD de  $Y$  será denotada  $U_Y \Sigma_Y V_Y^*$ .

Usando o método da captura <sup>instantânea</sup> para reconstruir  $U_y$ , encontramos:

$$U_y = Y V_A \Sigma_A^{-1} = C A V_A \Sigma_A^{-1} = C U_A$$

ou seja,

$$U_y = C U_A$$

$$\bar{\Sigma}_y = \bar{\Sigma}_A$$

$$V_y = V_A$$

$$Y = C A = C U_A \bar{\Sigma}_A^{-1} V_A^*$$

Agora, vamos considerar uma transf. unitária  $\bar{Z}$  linear,  $Y = A P^*$  cuja matriz de correlação

$$Y^* Y = P A^* A P^* = P V_A \bar{\Sigma}_A^{-2} V_A^* P^*$$

ou seja

$$Y^* Y P V_A = P V_A \bar{\Sigma}_A^{-2}$$

Assim,

$$V_y = P V_A$$

$$\bar{\Sigma}_y = \bar{\Sigma}_A$$

Podemos usar o método da captura para reconstruir  $U_y$

$$U_y = Y P V_A \bar{\Sigma}_A^{-1} = A V_A \bar{\Sigma}_A^{-1} = U_A$$



Portanto  $Uy = Ux$ , e a decomposição SVD de  $Y$

$$Y = AP^* = U_A \Sigma_A V_A^* P^*$$

Aplicação de SVD: matriz pseudo-inversa  
(Moore-Penrose)

$$B = U \Sigma V^*$$

$$B^+ \equiv V \Sigma^{-1} U^* \Rightarrow B^+ B = V V^*$$

Vamos considerar o sistema

$$Ax = b$$

$\left\{ \begin{array}{l} \text{indeterminado se} \\ A \in \mathbb{C}^{m \times n}, m \leq n \\ \text{Sobre determinado se} \\ m > n \end{array} \right.$

No caso de sobre determinado, quando não existe  
solução do sist., buscamos a solução  $x$  que  
minimiza a quantidade

$$\|b - Ax\|_2^2$$

Essa é a ~~melhor~~ solução ~~para~~ de mínimos quadrados  
(quadrados mínimos)

Já no caso de sist. indeterminado, quando infinitas  
soluções existem, podemos determinar a solução  $x$   
que minimiza a quantidade

$$\|x\|_2 \text{ tal que } Ax = b$$

(solução norma mínima)

Vamos utilizar a pseudo inversa de  $A$ , de seguinte forma

$$A^* A \tilde{x} = A^* b \Rightarrow \tilde{x} = \tilde{V} \tilde{\Sigma}^{-1} \tilde{U}^* b$$

independentemente se o sistema original é (over or under)

sobre ou indeterminado. temos que:

$$A \tilde{x} = \tilde{U} \tilde{\Sigma} \tilde{V}^* \tilde{V} \tilde{\Sigma}^{-1} \tilde{U}^* b = \tilde{U} \tilde{U}^* b$$

Note: Para decomposição exata SVD,  $\tilde{U} \tilde{U}^* = \tilde{U}^* \tilde{U} = I \in \mathbb{R}^{m \times m}$   
Isso não é válido para uma versão aproximada  
ou truncada do SVD.

$\tilde{x}$  é solução exata de  $Ax = b$  quando  $b$  está  
no espaço coluna de  $\tilde{U}$ , ou seja no espaço coluna  
de  $A$ .

Portanto, muito cuidado para não assumir ~~que~~

$\tilde{U} \tilde{U}^*$  como a matriz identidade, o que pode

ser assumido é  $\tilde{U} \tilde{U}^* = I \in \mathbb{R}^{r \times r}$ ,  $r$  o  
posto de  $A$ .